

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра математического обеспечения и применения ЭВМ

ОТЧЕТ
по проекту
по дисциплине «Обучение с подкреплением»
Тема: Реализация DQN с улучшениями

Студент гр. 1303

Преподаватель

Гусев Б.А.
Сидоров И.Н.

Глазунов С.А.

Санкт-Петербург

2026

1. Цель работы

Необходимо реализовать и сравнить между собой следующие версии DQN:

- Prioritized Replay
- Dueling Networks
- Noisy Net

В качестве окружения для тестирования:

- LunarLander-v3
- Mountain-Car

2. Описание сред

Среда LunarLander-v3 представляет собой лунный модуль, который необходимо безопасно посадить между двумя флагами.

Обладает следующим пространством состояний:

- Координаты модуля;
- Скорости модуля;
- Угловая скорость модуля;
- Наклон модуля;
- Касание левой или правой опоры поверхности.

Доступные действия:

- Запустить центральный двигатель;
- Запустить левый двигатель;
- Запустить правый двигатель;
- Ничего не делать.

Условия завершения:

- Модуль разбился;
- Модуль приземлился за границей флагов;
- Модуль не движется.

Среда Mountain-Car представляет собой машинку, движущуюся вдоль урезанной синусоиды. Её задача достичь вершины.

Обладает пространством состояний:

- Позиция машинки;
- Скорость машинки.

Доступные действия:

- Ускорение влево;
- Ускорение вправо;
- Не ускоряться.

Условия завершения:

- Машинка достигла вершины;
- Длина эпизода свыше 200 шагов.

3. Реализация алгоритма

Реализовывался алгоритм DQN. В нем функция QNetwork предназначена для оценки качества действия. Представлена в виде нейронной сети с нейронами входного слоя по числу состояний среды и выходного по числу возможных действий. Промежуточные слои задаются для различных экспериментов, в качестве активационной функции используется ReLU.

ReplayBuffer служит для стабилизации обучения за счет уменьшения корреляции между последовательными переходами. Его наличие позволяет учиться не на опыте текущего эксперимента, а на некотором случайном наборе экспериментов.

И, наконец, DQNAgent объединяет в себе эти элементы. Для большей стабильности обучаются две сети. Что бы не максимизировать оценки шума $\arg\max$ берется от одной сети, а оценка от другой. Заслуживают внимания следующие элементы реализации:

- Веса копируются не раз в n шагов, а постепенно;
- Обучение идет на цепочке шагов (5);

- Агент ориентирован на будущую прибыль;
- Действия от полностью случайных постепенно переходят к осмысленным.

Так же стоит отметить, что из-за особенностей среды Mountain Car её награда сильно разрежена. Поэтому, для достижения лучших результатов в работе используется преобразование награды на основании высоты машинки и её кинетической энергии.

Эпизоды циклически повторяются заданное число раз.

4. Применяемые улучшения DQN

В рамках экспериментов сравнивалась эффективность различных улучшений алгоритма DQN для предложенных сред. Использовались:

- Prioritized Replay. Измененный буфер. Вместо идеи, что все эпизоды обучения одинаково ценны основная работа ведется с попытками с высокой ошибкой, поскольку там агент может многому научиться. В представленной реализации для хранения используется бинарное дерево.
- Dueling Networks. Основной идеей является разделение сведений о ценности текущего состояния и преимуществе действия в нем. Это позволяет эффективнее обучаться в случаях с большим числом действий, поскольку сеть получает качественную оценку состояния без необходимости выполнения всех возможных действий в нем.
- Noisy Net. Основной идеей является использование зашумленных весов, что в конечном итоге позволяет преобразовать задачу подбора гиперпараметров из случайного выбора в свойство обучения модели.

5. Результаты экспериментов

В рамках 1-го эксперимента в среде LunarLander-v3 были получены следующие результаты обучения:




Рисунок 1 – Эксперимент 1

Как видно по графику, наилучшие результаты продемонстрировала модификация Prioritized Replay. Мы связываем это с тем, что выполняемая задача дает большой объем данных о попытках и имеет широкую свободу состояний, что позволяет эффективно обучаться с использованием наиболее ценных эпизодов. Модификация Dueling Networks конкурентоспособна, поскольку, как говорилось выше, задача позволяет получить множество данных для обучения и за счет этого на ранних этапах агент обучается быстро, но действий недостаточно много что бы раскрыть преимущества этого подхода, а более точный подбор обучающего набора на поздних этапах позволяет добиться лучших результатов. Модификация Noisy Net проигрывает, поскольку при такой плотной награде зашумленность весов только мешает агенту обучаться.

В рамках 2-го эксперимента в среде Mountain-Car были получены следующие результаты обучения:



Рисунок 2 – Эксперимент 2

Как видно по графику, наилучшие результаты продемонстрировала модификация Noisy Net. Мы связываем это с тем, что выполняемая задача, даже с учетом преобразования награды, не дает качественно обучаться до получения первого положительного примера и в ней случайности в весах, используемые в этом подходе, позволяют быстрее достигать результата.

6. Выводы

В рамках выполнения проекта были успешно реализованы модификации Prioritized Replay, Dueling Networks и Noisy Net архитектуры DQN для сред LunarLander-v3 и Mountain-Car и получены следующие результаты обучения:

Модификация	LunarLander-v3	MountainCar-v0
Prioritized Replay	287.3	-129.9
Dueling Network	282.2	-161.4
Noisy Net	247.1	-95.8